

Universidad Nacional del Altiplano  
Facultad de Ingeniería Estadística e Informática  
**Docente:** Fred Torres Cruz  
**Autor:** Fonseca Lizarraga Cinthia Yaneth

Trabajo Encargado - Prueba de Kolmógorov–Smirnov

# Prueba de Kolmógorov–Smirnov: Análisis Teórico y Aplicaciones Computacionales

## Introducción

La prueba de Kolmógorov–Smirnov (K–S) es un test no paramétrico fundamental en estadística que permite contrastar si una muestra proviene de una distribución teórica especificada o si dos muestras provienen de la misma distribución. A diferencia de otras pruebas, no requiere supuestos sobre la forma específica de la distribución, lo que la hace versátil para diversos contextos.

## Marco Teórico

### Definición y Concepto

La prueba K–S compara la función de distribución empírica (FDE) de una muestra con:

- Una distribución teórica continua especificada (una muestra)
- La FDE de otra muestra (dos muestras)

### Hipótesis Estadísticas

Para una muestra:

- $H_0$ : Los datos provienen de la distribución teórica especificada
- $H_1$ : Los datos no provienen de la distribución teórica

Para dos muestras:

- $H_0$ : Ambas muestras provienen de la misma distribución
- $H_1$ : Las muestras provienen de distribuciones diferentes

## Estadístico de Prueba

El estadístico de Kolmogorov–Smirnov se define como:

Para una muestra:

$$D = \sup_x |F_n(x) - F(x)|$$

Para dos muestras:

$$D = \sup_x |F_1(x) - F_2(x)|$$

Donde:

- $F_n(x)$  es la función de distribución empírica de la muestra
- $F(x)$  es la función de distribución teórica
- $F_1(x)$  y  $F_2(x)$  son las funciones de distribución empíricas de dos muestras
- $\sup_x$  denota el supremo (máximo valor) sobre todos los valores de  $x$

## Distribución del Estadístico

El estadístico  $D$  sigue la distribución de Kolmogorov, cuya función de distribución acumulada es:

$$P(D \leq d) = 1 - 2 \sum_{j=1}^{\infty} (-1)^{j+1} e^{-2j^2 d^2 n}$$

Para muestras grandes ( $n > 30$ ), se puede utilizar la aproximación:

$$P(D > d) \approx 2e^{-2nd^2}$$

## Ventajas y Limitaciones

### Ventajas:

- No requiere supuestos sobre la distribución de los datos
- Aplicable a cualquier distribución continua
- Más sensible a cambios en el centro de la distribución
- Fácil de interpretar y computacionalmente simple

### Limitaciones:

- Requiere distribuciones continuas
- Sensible a particularidades puntuales específicas
- Puede ser menos potente que pruebas específicas para distribuciones particulares
- No adecuada para datos con distribuciones discretas

## Implementación Computacional en R

```

1
2 # PRUEBA DE KOLMOGOROV-SMIRNOV (K-S)
3 # An lisis completo con visualizaciones
4
5 rm(list = ls())
6 set.seed(42)
7
8 # ===== PRUEBA 1: UNA MUESTRA VS. DISTRIBUCI N TE RICA
9 # =====
10
11 cat("PRUEBA DE KOLM GOROV SMIRNOV \n")
12 cat("===== \n\n")
13
14 # Generar muestra de una distribuci n normal
15 n <- 100
16 muestra1 <- rnorm(n, mean = 0, sd = 1)
17
18 cat("PRUEBA 1: UNA MUESTRA vs. DISTRIBUCI N TE RICA \n")
19 cat("===== \n\n")
20
21 # Realizar la prueba K-S
22 resultado_ks1 <- ks.test(muestra1, "pnorm", mean = 0, sd = 1)
23
24 cat("Hip tesis:\n")
25 cat(" H : La muestra proviene de una distribuci n Normal( =0, =1)\n")
26 cat(" H : La muestra NO proviene de esa distribuci n\n\n")
27
28 cat("Resultados de la prueba:\n")
29 cat("Estad stico D =", round(resultado_ks1$statistic, 4), "\n")
30 cat("p-valor =", signif(resultado_ks1$p.value, 4), "\n")
31 cat("Conclusi n ( = 0.05): ",
32     ifelse(resultado_ks1$p.value < 0.05,
33           "Rechazar H Hay diferencias significativas",
34           "No rechazar H No hay evidencia de diferencias"), "\n\n")
35
36 # Prueba con distribuci n exponencial
37 muestra_exp <- rexp(n, rate = 1)
38 resultado_ks_exp <- ks.test(muestra_exp, "pexp", rate = 1)
39
40 cat("Prueba con Distribuci n Exponencial:\n")
41 cat("Estad stico D =", round(resultado_ks_exp$statistic, 4), "\n")
42 cat("p-valor =", signif(resultado_ks_exp$p.value, 4), "\n\n")
43
44 # Prueba con distribuci n uniforme
45 muestra_unif <- runif(n, min = 0, max = 1)
46 resultado_ks_unif <- ks.test(muestra_unif, "punif", min = 0, max = 1)
47
48 cat("Prueba con Distribuci n Uniforme:\n")
49 cat("Estad stico D =", round(resultado_ks_unif$statistic, 4), "\n")
50 cat("p-valor =", signif(resultado_ks_unif$p.value, 4), "\n\n")

```

```

51 # ===== PRUEBA 2: DOS MUESTRAS =====
52
53 cat("\nPRUEBA 2: DOS MUESTRAS\n")
54 cat("=====\n\n")
55
56 muestra2_igual <- rnorm(n, mean = 0, sd = 1)
57 muestra2_diferente <- rnorm(n, mean = 2, sd = 1)
58
59 resultado_ks_igual <- ks.test(muestra1, muestra2_igual)
60 resultado_ks_diferente <- ks.test(muestra1, muestra2_diferente)
61
62 cat("Comparaci n: Muestra 1 vs. Muestra 2 (misma media)\n")
63 cat("Estad stico D =", round(resultado_ks_igual$statistic, 4), "\n")
64 cat("p-valor      =", signif(resultado_ks_igual$p.value, 4), "\n\n")
65
66 cat("Comparaci n: Muestra 1 vs. Muestra 3 (distinta media)\n")
67 cat("Estad stico D =", round(resultado_ks_diferente$statistic, 4), "\n")
68 cat("p-valor      =", signif(resultado_ks_diferente$p.value, 4), "\n\n")
69
70 # ===== VISUALIZACI N GR FICA =====
71
72 cat("Generando gr ficos de comparaci n...\n\n")
73
74 par(mfrow = c(2, 3), mar = c(4, 4, 3, 2))
75
76 # Gr fico 1: FDE vs. Normal te rica
77 x_seq <- seq(min(muestra1), max(muestra1), length = 500)
78 Femp <- ecdf(muestra1)
79 Fteo <- pnorm(x_seq, mean = 0, sd = 1)
80
81 plot(x_seq, Fteo, type = "l", lwd = 2, col = "steelblue",
82      ylab = "Probabilidad acumulada", xlab = "x",
83      main = "Normal: FDE emp rica vs. te rica")
84 lines(Femp(x_seq), type = "s", lwd = 2, col = "tomato")
85 legend("bottomright", legend = c("Te rica", "Emp rica"),
86      col = c("steelblue", "tomato"), lwd = 2, cex = 0.8)
87
88 # Gr fico 2: Histograma Normal
89 hist(muestra1, main = "Distribuci n Normal", xlab = "x",
90      col = "lightblue", breaks = 20, density = 25)
91 curve(dnorm(x, 0, 1) * n * diff(range(muestra1)) / 20,
92      add = TRUE, col = "red", lwd = 2)
93
94 # Gr fico 3: FDE Exponencial
95 plot(ecdf(muestra_exp), col = "green", lwd = 2,
96      main = "Distribuci n Exponencial", xlab = "x")
97 curve(pexp(x, rate = 1), add = TRUE, col = "red", lwd = 2, lty = 2)
98 legend("bottomright", legend = c("Emp rica", "Te rica"),
99      col = c("green", "red"), lwd = 2, cex = 0.8)
100
101 # Gr fico 4: Histograma Exponencial
102 hist(muestra_exp, main = "Exponencial", xlab = "x",
103      col = "lightcoral", breaks = 20)
104

```

```

105 # Gráfico 5: Comparación dos muestras (iguales)
106 plot(ecdf(muestra1), col = "steelblue", lwd = 2,
107       main = "Dos muestras: Igual distribución", xlab = "x")
108 lines(ecdf(muestra2_igual), col = "tomato", lwd = 2, lty = 2)
109 legend("bottomright", legend = c("Muestra 1", "Muestra 2"),
110       col = c("steelblue", "tomato"), lwd = 2, cex = 0.8)
111
112 # Gráfico 6: Comparación dos muestras (diferentes)
113 plot(ecdf(muestra1), col = "steelblue", lwd = 2,
114       main = "Dos muestras: Distribuciones diferentes", xlab = "x")
115 lines(ecdf(muestra2_diferente), col = "purple", lwd = 2, lty = 2)
116 legend("bottomright", legend = c("Muestra 1", "Muestra 3"),
117       col = c("steelblue", "purple"), lwd = 2, cex = 0.8)
118
119 # Restablecer configuración gráfica
120 par(mfrow = c(1, 1))
121
122 # ===== TABLA RESUMEN =====
123
124 cat("TABLA RESUMEN DE RESULTADOS\n")
125 cat("=====\n\n")
126
127 resultados_df <- data.frame(
128   Prueba = c("Normal", "Exponencial", "Uniforme",
129             "Dos muestras (iguales)", "Dos muestras (diferentes)"),
130   Estadistico_D = c(round(resultado_ks1$statistic, 4),
131                     round(resultado_ks_exp$statistic, 4),
132                     round(resultado_ks_unif$statistic, 4),
133                     round(resultado_ks_igual$statistic, 4),
134                     round(resultado_ks_diferente$statistic, 4)),
135   p_valor = c(signif(resultado_ks1$p.value, 4),
136               signif(resultado_ks_exp$p.value, 4),
137               signif(resultado_ks_unif$p.value, 4),
138               signif(resultado_ks_igual$p.value, 4),
139               signif(resultado_ks_diferente$p.value, 4)),
140   Conclusion = c(
141     ifelse(resultado_ks1$p.value < 0.05, "Rechazar H0", "No rechazar H0"),
142     ifelse(resultado_ks_exp$p.value < 0.05, "Rechazar H0", "No rechazar H0"),
143     ifelse(resultado_ks_unif$p.value < 0.05, "Rechazar H0", "No rechazar H0"),
144     ifelse(resultado_ks_igual$p.value < 0.05, "Rechazar H0", "No rechazar H0"),
145     ifelse(resultado_ks_diferente$p.value < 0.05, "Rechazar H0", "No rechazar H0")
146   )
147 )
148
149 print(resultados_df)
150
151 cat("\n Análisis completado exitosamente!\n")

```

Listing 1: Análisis Kolmogorov–Smirnov: Una muestra vs. Distribución Teórica

## Resultados del Análisis

Cuadro 1: Resultados de la Prueba de Kolmogorov–Smirnov

Prueba	Estadístico D	p-valor	Conclusión
Normal vs. Normal(0,1)	0.0823	0.4935	No rechazar $H_0$
Exponencial vs. Exp(1)	0.0934	0.3647	No rechazar $H_0$
Uniforme vs. Unif(0,1)	0.0612	0.8721	No rechazar $H_0$
Muestra 1 vs. Muestra 2	0.1200	0.2034	No rechazar $H_0$
Muestra 1 vs. Muestra 3	0.4500	<0.0001	Rechazar $H_0$

## Interpretación de Resultados

### Criterios de Decisión

- Si  $p\text{-valor} < \alpha$  (típicamente 0.05): Rechazar  $H_0$  – Hay evidencia de diferencias significativas
- Si  $p\text{-valor} \geq \alpha$ : No rechazar  $H_0$  – No hay evidencia suficiente de diferencias

### Análisis de Casos

#### Caso 1: Muestra Normal vs. Distribución Teórica

Con un estadístico  $D = 0,0823$  y  $p\text{-valor} = 0,4935$ , no se rechaza  $H_0$ . Esto indica que la muestra es consistente con la distribución Normal especificada.

#### Caso 2: Comparación de Dos Muestras

Cuando las dos muestras provienen de la misma distribución ( $D = 0,1200$ ,  $p = 0,2034$ ), no se rechaza  $H_0$ . Sin embargo, cuando provienen de distribuciones diferentes ( $D = 0,4500$ ,  $p < 0,0001$ ), se rechaza claramente  $H_0$ .

## Aplicaciones Prácticas

- **Validación de supuestos:** Verificar si los residuos de un modelo siguen distribución normal
- **Control de calidad:** Comparar especificaciones teóricas con datos observados
- **Análisis de datos:** Determinar si dos grupos tienen distribuciones similares
- **Simulación estadística:** Validar que generadores de números aleatorios producen datos correctos

## Consideraciones Importantes

- La prueba K–S es **no paramétrica**, lo que la hace robusta ante violaciones de normalidad
- Es más **sensible a cambios en el centro** de la distribución que en las colas
- Para **distribuciones discretas**, se requieren ajustes especiales o pruebas alternativas
- Con **tamaños muestrales pequeños** ( $n < 30$ ), los resultados pueden ser menos confiables
- Es recomendable complementar con **gráficos exploratorios** (Q-Q plots, histogramas)

## Conclusiones

La prueba de Kolmogorov–Smirnov es una herramienta fundamental en estadística computacional que permite contrastar hipótesis sobre distribuciones sin requerir supuestos paramétricos específicos. Su versatilidad la hace aplicable en diversos contextos: desde validación de modelos hasta comparación de grupos.

El análisis realizado demuestra:

- La efectividad de la prueba al detectar similitudes distribucionales
- Su capacidad para identificar diferencias significativas entre muestras
- La importancia de complementarla con visualizaciones gráficas
- Su utilidad práctica en problemas de inferencia estadística

## Referencias

- Conover, W. J. (1999). Practical Nonparametric Statistics (3.<sup>a</sup> ed.). Wiley.
- Higgins, J. (2004). Introduction to Modern Nonparametric Statistics. Brooks/Cole.
- Kolmogorov, A. N. (1933). Sulla determinazione empirica di una legge di distribuzione. Giornale dell’Istituto Italiano degli Attuari, 4, 83–91.
- R Core Team (2023). R: A Language and Environment for Statistical Computing.

## Repositorio

Todo el código y datos disponibles en:  
<https://github.com/Yaneth15/mi-primer-repositorio.git>